

Durée : 2 heures

Documents, calculatrices, téléphones mobiles, ordinateurs portables interdits (liste non exhaustive)

Exercice 1. (1 point) Soit $x = \text{bababbab}$. Donner un automate fini déterministe \mathcal{A} tel que $\mathcal{L}(\mathcal{A}) = \text{Fact}(x)$ (utiliser un *trie*).

Exercice 2. (6 points) Effectuer la recherche de $x = \text{babbaa}$ dans $y = \text{abbaababbababbabbaa}$ avec :

- un automate de recherche (donner l'automate reconnaissant A^*x et les états atteints lors de l'examen de chaque lettre de y) ;
- l'algorithme de Knuth, Morris et Pratt (donner la table *meil-préf* et les comparaisons effectuées lors de chaque tentative) ;
- l'algorithme de Boyer-Moore (donner les tables *bon-suff* et *dern-occ* et les comparaisons effectuées lors de chaque tentative).

Exercice 3. (3 points) Effectuer la recherche exacte de $x = \text{agac}$ dans $y = \text{agagatgac}$ avec une inégalité avec l'algorithme Shift-Or.

Donner les vecteurs S sur 4 bits pour les lettres **a**, **c**, **g** et **t**. Donner les vecteurs initiaux R^0 et R^1 sur 4 bits et pour chaque position sur y .

Exercice 4. (3 points) Construire la machine de Aho-Corasick pour l'ensemble fini de mots $X = \{\text{ababa}, \text{abba}, \text{bba}, \text{babb}\}$.

Utiliser cette machine pour rechercher les occurrences des mots de X dans $y = \text{abbaababbababbabbaa}$ (donner les états atteints lors de l'examen de chaque lettre de y).

Exercice 5. (3 points) Compression

Rappel : les codes ASCII de **a**, **c**, **g** et **t** sont respectivement 97, 99, 103 et 116.

Coder **agagatgac** avec la méthode de Huffman.

Rappels : on code à la fois l'arbre et le texte à coder.

Exercice 6. (4 points) Soit $A = \{a_0, a_1, a_2, \dots\}$ un alphabet ordonné. Soit u_n la suite définie comme suit :

- $u_0 = \varepsilon$;
- $u_i = u_{i-1}a_{i-1}u_{i-1}$ pour $i \geq 1$.

- Donner u_1 , u_2 , u_3 et u_4 .
- Donner les longueurs de u_0 , u_1 , u_2 , u_3 , u_4 . Généraliser pour u_i .
- Donner le nombre de bords de u_0 , u_1 , u_2 , u_3 , u_4 . Généraliser pour u_i .
- Soit $D(\{x\}) = (A, Q, q_0, F, T)$ l'automate fini déterministe reconnaissant le langage $A^*\{x\}$ pour un mot $x \in A^*$.

On note $C(p)$ le nombre d'états distincts cibles de transition de source l'état p .

Formellement :

$$C(p) = \text{card}\{q \in Q \mid (p, a, q) \in F\}.$$

Donner $C(u_i)$ pour $D(\{u_i\})$.