

Compilation

M. Patrou

2013 / 2014

Jérémy Hébert

Sommaire

Chapitre 1 : Introduction (début et fin 12/09/2013).....	3
Définition compilateur	3
Analyseur lexical	3
Analyseur syntaxique.....	4
Analyseur sémantique	4
Générateur de code intermédiaire	5
Optimiseur de code	5
Générateur de code.....	5
Remarques.....	5
Chapitre 2 : Un traducteur Infixe – post fixe (début 12/09/2013, fin 18/09/2013)	6
Notations et définitions	6
2.1 Ambiguïté.....	7
2.2 Associativité et priorité	8
2.3 Analyse syntaxique descendantes	10
2.4 Récursivité gauche et factorisation gauche	11
Grammaire récursive gauche	11
2.5 Définition dirigée par la syntaxe	13
2.6 Schéma de traduction	13
2.7 Une version C du traducteur	15
2.8 L’analyseur lexical et la table des symboles 18 / 09	15
Chapitre 3 : Analyse lexicale (début et fin : 18/09/2013)	16
Chapitre 4 : Analyse syntaxique.....	18
4.1 Analyse descendante	18
4.2 Grammaire LL(1)	20
4.3 Analyse ascendante	25
Chapitre 5 : Traduction dirigée par la syntaxe (début 16/10/2013 – fin).....	35
5.1 Attributs.....	35
5.2 Définitions S-attribuées	36
5.2.1 Analyse ascendante	37
5.2.2 Analyse descendante	38
5.3 Définitions L-attribuées.....	39
5.3.1 Analyse descendante	39
5.3.2 Analyse ascendante	42

Chapitre 1 : Introduction (début et fin 12/09/2013)

Présentation Générale

Définition compilateur

Un compilateur est un logiciel qui permet de lire un flot de données écrit dans un premier langage, appelé langage source, pour le traduire en un flot de sortie écrit dans un second langage, appelé le langage cible.

Un rôle secondaire important à signaler la présence d'erreurs dans le flot d'entrée.

Beaucoup de compilateur (du fait de la variété des langages sources et cibles). Tous sont conçus sur un même schéma qui distingue deux phases :

- La phase d'analyse (ou partie frontale du compilateur) dépend principalement du langage source. Il s'agit de reconstruire sous une forme intermédiaire la structure syntaxique du flot d'entrée.
- La phase de synthèse (ou partie finale du compilateur) dépend du langage cible. Elle a pour objet l'optimisation du code intermédiaire puis la production du code final.

Flot d'entrée -> Analyseur lexical -> Analyseur syntaxique -> Analyser sémantique -> générateur de code intermédiaire -> optimiseur de code -> générateur de code -> Flot de sortie (**Schéma à refaire voir Alexis**).

Toutes ces étapes utilisent le gestionnaire de la table des symboles et le gestionnaire d'erreurs.

Schéma 1

Analyseur lexical

L'analyseur lexical lit séquentiellement le flot d'entrée et le découpe en lexèmes (ou unités lexicales) qui sont des suites de symboles qui ont une signification collective.

Exemple : position := initiale + vitesse x 60

Conduit au découpage :

- | | |
|--------------------------------|--------|
| - Un identificateur : position | ID |
| - Un symbole d'affection := | AFFECT |
| - Un identificateur : initiale | ID |
| - L'opérateur + | '+' |
| - Un identificateur : vitesse | ID |
| - L'opérateur * | '*' |
| - Le nombre 60 | NB |

Chaque lexème appartient à une classe (identifiée par une constante symbolique). Certaines classes sont des singletons et peuvent être confondues avec l'unique lexème qu'elles contiennent. D'autres contiennent plusieurs éléments.

A la sortie de l'analyseur lexical on obtient : ID1 AFFECT ID2 '+' ID3 '*' NB

ID1, ID2 et ID3 sont, en fait, associés à des entrées dans la table des symboles.

Au passage : suppression des éléments non significatifs (blancs, tabulation, retour chariot, commentaires, ...).

Les classes de lexèmes sont descriptibles par des langages rationnels (utilisation d'automates).

Analyseur syntaxique

L'analyseur syntaxique consiste à construire la structure grammaticale sous-jacente au flot de lexèmes.

On a besoin d'une description grammaticale (grammaire algébrique) du langage source.

Concrètement : construction d'un arbre.

Instruction -> ID AFFECT expression

Expression -> expression '+' expression

Expression -> expression '*' expression

Expression -> ID

Expression -> NB

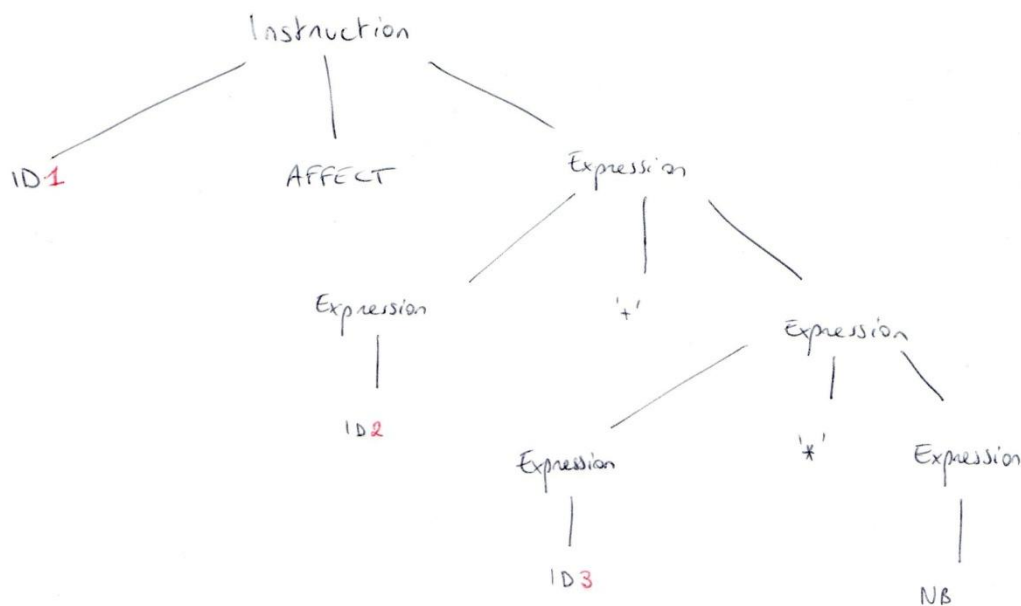


Figure 1.

Figure 1 : arbre exemple

Analyseur sémantique

L'analyseur sémantique utilise cet arbre pour collecter diverses informations et contrôler la validité de certaines constructions (l'utilisation de réels pour indiquer un tableau, une discordance sur le nombre et le type des arguments d'une fonction entre sa signature et un appel donné, ...).

Une part importante de son rôle est la vérification du type des différents éléments apparaissant dans l'arbre (cette information est à stocker dans la table des symboles).

Sur notre exemple, le type des 3 identificateurs doit être vérifié pour assurer leur comptabilité. Une coercion de type (transtypage) est possible pour le nombre si ID3 est de type réel.

Générateur de code intermédiaire

Le générateur de code intermédiaire produit du code pour une machine abstraite.

<pre>tmp1 := entierVersReel(60) tmp2 := Id3 * tmp1 tmp3 := Id2 + tmp2 id1 := tmp3</pre>	} code à 3 adresses
---	---------------------

Optimiseur de code

L'optimiseur de code recherche d'efficacité et de compacité.

```
tmp1 := id3 * 60.0
id1 := id2 + tmp1
```

Générateur de code

Le générateur de code permet :

- L'assignation des ressources mémoires
- L'affectation des registres

```
MOVF id3, R2
MULF #60.0, R2
MOVF id2, R1
ADDF R2, R1
MOVF R1, id1
```

Remarques

- 6 étapes pas aussi distinctes que le laisse penser le schéma
Par exemple, l'analyseur syntaxique pilote souvent la partie frontale du compilateur. Il veut construire un arbre interpele l'analyse lexical en flot de ses besoins pour avancer dans sa construction. Il peut aussi stimuler l'analyseur sémantique quand il dispose d'une portion d'arbre « suffisante ».
- Le découpage entre étapes n'est pas immédiat.

Analyseur lexical	Analyseur syntaxique
Langage rationnel	Langage algébrique
automates	Grammaire algébrique

Outils d'aide à la conception de compilateur :


- Lex : logiciel C construisent automatiquement un analyseur lexical (également en C) à partir d'une description des lexèmes du langage source.
- Yacc (Yet Another Compiler Compiler) : construit un analyseur syntaxique (en C) à partir d'une grammaire.

Chapitre 2 : Un traducteur Infixe – post fixe (début 12/09/2013, fin 18/09/2013)

Expression infixe -> (traducteur) expression postfixe

Expression infixe : opérateurs binaires situés entre leurs opérandes.

Expression postfixe : opérateurs binaires situés après leurs opérandes.



On voit que l'analyseur syntaxique va mener les opérations. L'analyseur sémantique et le générateur du code intermédiaire lui sont tellement liés que ces 3 phases sont considérées comme n'en constituant plus qu'une.

Spécifions donc l'analyseur syntaxique. Il nous faut une grammaire décrivant le langage source :

$E \rightarrow E + E \mid E - E \mid E * E \mid E / E \mid (E) \mid nb$

Notations et définitions

- Une grammaire peut être vue comme un sujet de réécriture où chaque production de la grammaire de la forme $A \rightarrow \alpha$ peut être utilisée pour remplacer n'importe quelle occurrence de A par α .

$E \rightarrow E + E \rightarrow nb + E \rightarrow nb + nb$

Suite de 3 réécritures permettant de dériver E en nb + nb. Formellement, pour une grammaire G d'axiome S.

- o Une réécriture $\alpha\beta \rightarrow \alpha\gamma\beta$ où \rightarrow se lit « se dérive en une étape » est autorisée si $A \rightarrow \gamma$ est une production de G et α, β sont des chaînes quelconques.
- o Le symbole $\xrightarrow{*}$ signifie « se dérive en 0, 1 ou plusieurs étapes en ».
- o Le symbole $\xrightarrow{+}$ signifie « se dérive en 1 ou plusieurs étapes en ».
- o Une suite de réécritures est appelée une G-dérivation (ou plus simplement dérivation). Si $\alpha \xrightarrow{*} \beta$ alors on dit qu'il existe une dérivation de α en β (ou de β à partir de α). Et si $\alpha = S$ on dit simplement qu'il existe une dérivation de β .
- o Si $S \xrightarrow{*} \alpha$ on dit que α est une proto-phrasede G.
- o Une phrase de G est une proto-phrasede G ne contenant pas de symboles non-terminaux.
- o Une dérivation dans laquelle le non-terminal le plus à gauche (respectivement le plus à droite) est réécrit à chaque étape est appelée une dérivation gauche (resp. droite).
- Une grammaire peut aussi être vue comme la description d'un procédé de construction d'arbre. La racine de l'arbre est étiquetée par l'axiome et de chaque nœud étiquetée A est issu un ensemble de fils étiquetés par le symbole de la partie droite d'une A-production. Les feuilles sont étiquetées par des symboles terminaux. On parle d'arbre syntaxique ou d'arbre de dérivation.

La suite de ses feuilles lues en ordre préfixe est le mot engendré par cet arbre.




Figure 2

Figure 2 : schéma d'un arbre traitant le parcours préfixe.

- Pour une grammaire donnée, il y a bijection entre l'ensemble des arbres syntaxiques générés par cette grammaire et l'ensemble des dérivations gauches (ou droites) des phrases de cette grammaire.

2.1 Ambiguïté

Notre grammaire est ambiguë -> pb

Définition : une grammaire est ambiguë si elle permet de construire arbres syntaxiques distincts engendrant le même mot.

9 - 5 + 2




Figure 3 :

Figure 3




Figure 4

Un analyseur syntaxique ne peut être basé sur une grammaire ambiguë (il ne saura pas quel arbre construire).

Proposer une autre grammaire (non ambiguë)

Ici, c'est possible

En général : non -> il existe des langages inhéremment ambigus

2.2 Associativité et priorité

La grammaire est ambiguë car les propriétés d'associativité et de priorité des opérateurs ne sont pas prises en compte

Priorité : on règle le problème en introduisant un symbole non-terminal supplémentaire pour chaque niveau de priorité souhaité :

$E \rightarrow E + E \mid E - E \mid T$

$T \rightarrow T * T \mid T / T \mid F$

$F \rightarrow (E) \mid nb$




Figure 5

Associativité : conventionnellement, les 4 opérateurs arithmétiques sont associatifs à gauche.

$$8 - 4 - 1 \Rightarrow (8 - 4) - 1 = 3$$

$$\Rightarrow 8 - (4 - 1) = 5$$

On gère cette question en cassant les symétries des parties droites de production

$$E \rightarrow E + T \mid E - T \mid T$$

$$T \rightarrow T * F \mid T / F \mid F$$

$$F \rightarrow (E) \mid \text{nb}$$




Figure 6

$$I \rightarrow \text{id} = I \mid \text{id}$$

Affectation associative à droite (en C)

$$A = b = c$$

2.3 Analyse syntaxique descendantes

Principe de ce type d'analyse :

Type -> type_simple

| ^id

| array[type_simple] of type

Type_simple -> integer

| char

| nb 2 points nb

Array [nb 2points nb] of integer




Figure 7

Backtracking -> essai – erreur.

L'arbre est construit en parallèle avec la lecture du flot d'entrée.

Le nœud courant (au départ : l'axiome à la racine) est dérivé en flot du prochain lexème lu sur l'entrée.

En général, plusieurs possibilités peuvent survenir. On procède par essais-erreur. Procédé naturel et intuitif, mais trop coûteuse dans le cas général (on envisagera, plus tard, des approches non récursives)

Pour éliminer le principe d'essais-erreurs :

PREMIER(type_simple) = { integer, char, nb }

PREMIER (^id) = { ^ }

PREMIER(array[type_simple] of type) = {array}

2.4 Récursivité gauche et factorisation gauche

Pas d'analyseur syntaxique automatiquement produit en cas de :

- Grammaire réursive gauche.
- Grammaire non factorisée à gauche

Grammaire réursive gauche

Elle contient une production de la forme $A \rightarrow A\alpha \mid \beta$

Supposons que le prochain symbole de pré- vision appartienne à $\text{PREMIER}(\beta)$. L'analyseur ne peut pas savoir combien de fois derivier A en $A\alpha$ avant d'utiliser $A \rightarrow \beta$

Elimination de la réursive gauche :

$$A \rightarrow \beta R$$

$$R \rightarrow \alpha R \mid \epsilon$$




Figure 8

$$E \rightarrow E + T \mid E - T \mid T$$

$$T \rightarrow T * F \mid T / F \mid F$$

$$F \rightarrow (E) \mid \text{nb}$$

On applique la méthode :

$$E \rightarrow T E'$$

$$E' \rightarrow +T E' \mid -T E' \mid \epsilon$$

$$T \rightarrow F T'$$

$$T' \rightarrow * F T' \mid / F T' \mid \epsilon$$

$$F \rightarrow (E) \mid \text{nb}$$

On a :

$$S \rightarrow Aa \mid b$$

$$A \rightarrow Ac \mid Sd \mid c$$

Algorithme d'élimination des récursives gauches :

1. On ordonne les non-terminaux A_1, A_2, \dots, A_n

2. Pour i allant de 1 à n faire

Pour j allant de 1 à $i - 1$ faire

 Remplacer chaque production de la forme $A_i \rightarrow A_j \gamma$

 Les productions $A_i \rightarrow \delta_1 \gamma \mid \dots \mid \delta_k \gamma$ où $A_j \rightarrow \delta_1 \mid \delta_2 \mid \dots \mid \delta_k$ sont toutes les A_j productions courantes.

Fin pour

 Éliminer les récursives gauches immédiates des A_i productions.

Fin pour

Légende :

A_1, α_2 : rouge

B : vert

$i < 1$ rien à faire

$i < 2$ $j < 1$

$A \rightarrow A c \mid A a d \mid b d \mid c$

$A \rightarrow b d A' \mid c A'$

$A' \rightarrow c A' \mid a d A' \mid \epsilon$

Inverser boucle externe :

Pour tout $k < i$, s'il existe une production de la forme

$A_k \rightarrow A_k' \alpha$

Alors $k' > k$

Inverser boucle interne :

S'il existe une production de la forme

$A_i \rightarrow A_k' \alpha$

Alors $k' > j - 1$

J est un compteur.

Remarque : cet algorithme n'élimine les récursives gauches que si la grammaire initiale ne contient ni cycle ($A \xrightarrow{+} A$), ni une production vide (sauf éventuellement $S \rightarrow \epsilon$ où S est l'axiome).

$A \rightarrow A \mid \beta$ devient

$A \rightarrow \beta A'$

$A' \rightarrow A' \mid \epsilon$

$A \rightarrow C a$

$B \rightarrow \epsilon$

$C \rightarrow B A$ devient :

$A \rightarrow C a$

$B \rightarrow \epsilon$

$C \rightarrow A$

Il existe des algorithmes d'élimination des cycles et des ϵ -productions.

- Problème de l'absence de factorisation gauche : survient quand les parties droites de différentes A-production commençant par des symboles identiques.

Factorisation :

$E \rightarrow ER \mid T$

$R \rightarrow +T \mid -T$

2.5 Définition dirigée par la syntaxe

On va utiliser l'arbre produit par l'analyseur syntaxique en y ajoutant des infos supplémentaires.

On associe un ensemble d'attributs à chaque symbole grammatical. On définit des règles de calcul pour ces attributs (règles sémantiques).

Grammaire

+

Règles sémantiques

définition dirigée par la syntaxe.

Productions :	Règles sémantiques
$E \rightarrow E_1 + T$	$E.t := E_1.t \mid T.t \mid '+'$
$E \rightarrow E_1 - T$	$E.t := E_1.t \mid T.t \mid '-'$
$E \rightarrow T$	$E.t := T.t$
$T \rightarrow T_1 * F$	$T.t := T_1.t \mid F.t \mid '*'$
$T \rightarrow T_1 / F$	$T.t := T_1.t \mid F.t \mid '/'$
$T \rightarrow F$	$T.t := F.t$
$F \rightarrow (E)$	$F.t := E.t$
$F \rightarrow nb$	$F.t = nb \text{ vallex (valeur lexicale).}$




Figure 9

2.6 Schéma de traduction

On souhaite insérer des actions exécutables par un traducteur dans l'arbre syntaxique. Par $R \rightarrow +T \{ \text{imprimer}('+') \} R$




Figure 10

Le schéma de traduction associé à la définition dirigée par la syntaxe précédente :

$E \rightarrow E + T \{ \text{imprimer}(' + ') \}$

$E \rightarrow E - T \{ \text{imprimer}(' - ') \}$

$E \rightarrow T$

$T \rightarrow T * F \{ \text{imprimer}(' * ') \}$

$T \rightarrow T / F \{ \text{imprimer}(' / ') \}$

$T \rightarrow F$

$F \rightarrow (E)$

$F \rightarrow \text{nb} \{ \text{imprimer}(\text{nb.vallex}) \}$

Sans la récursive gauche :

$E \rightarrow T E'$

$E' \rightarrow +T \{ \text{imprimer}(' + ') \} E'$

$E' \rightarrow \epsilon$

$T \rightarrow F T'$

$T' \rightarrow * F \{ \text{imprimer}(' * ') \} T'$

$T' \rightarrow / F \{ \text{imprimer}(' / ') \} T'$

$T' \rightarrow \epsilon$

$F \rightarrow (E)$

$F \rightarrow \text{nb} \{ \text{imprimer}(\text{nb.vallex}) \}$

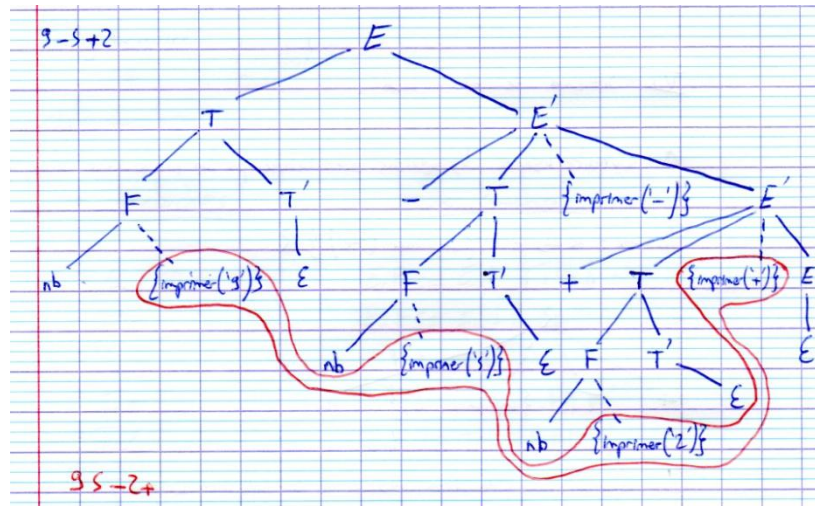


Figure 11

2.7 Une version C du traducteur

Voir Poly.

2.8 L'analyseur lexical et la table des symboles 18 / 09

L'analyseur lexical doit éliminer les caractères non significatifs et reconnaître :

- Des entiers
- Les opérateurs + - * /
- Les parenthèses et les points virgule
- La fin de fichier
-

Solution : switch + quelques getChar().

Quand un entier est reconnu une constante symbolique (NB) est renvoyée à l'analyseur syntaxique accompagnée de la valeur entière (via une variable globale).

Dans les autres cas on retourne simplement le caractère repéré.

Quelques ingrédients supplémentaires :

- Des identificateurs,
- Des mots clés dans le langage source (DIV et MOD)

Quand un identificateur est détecté, l'analyseur lexical le recherche dans la table des symboles (et l'y insère s'il ne le trouve pas). Son indice dans la table fait office de valeur lexicale à retourner à l'analyseur syntaxique, accompagnée de la constante ID.

Les mots clés sont traités à l'identique, mais sont insérés dans la table à l'initialisation du traducteur.

Table des symboles : tableau d'enregistrement à 2 champs :

- Classe du lexème
- Représentation (string) du lexème.

Traducteur peu robuste, peu ergonomique

3 _ + toto _ - 2

Problème si l'utilisateur oublie ce blanc (le scanf « mange » tout jusqu'à rencontrer un blanc ou un retour chariot).

2 _ + 2 ;

x _ * 3 ;

; => erreur (les expressions vides ne sont pas prévues par la grammaire).

Chapitre 3 : Analyse lexicale (début et fin : 18/09/2013)

Rôle principal : transformer un flot de caractère en un flot de lexèmes.

Services supplémentaires :

- Elimination des caractères non significatifs
- Décompte des lignes (pour permettre la localisation d'erreur syntaxique).
- Stockage des lexèmes dans la table des symboles
- Signalisation d'erreurs.

En pratique, c'est un sous-programme du service de l'analyseur syntaxique mais une conception séparée accroît la modularité de compilation et présente plusieurs avantages :

- Simplicité (intégrer la spécification des unités lexicales dans la grammaire l'alourdit considérablement).
- Efficacité (un module spécialisé est plus facile à optimiser)
- Portabilité (les spécificités lexicales sont confinées à l'analyseur lexical).

Les unités lexicales sont, en principe, spécifiées par des automates.

Exemples :

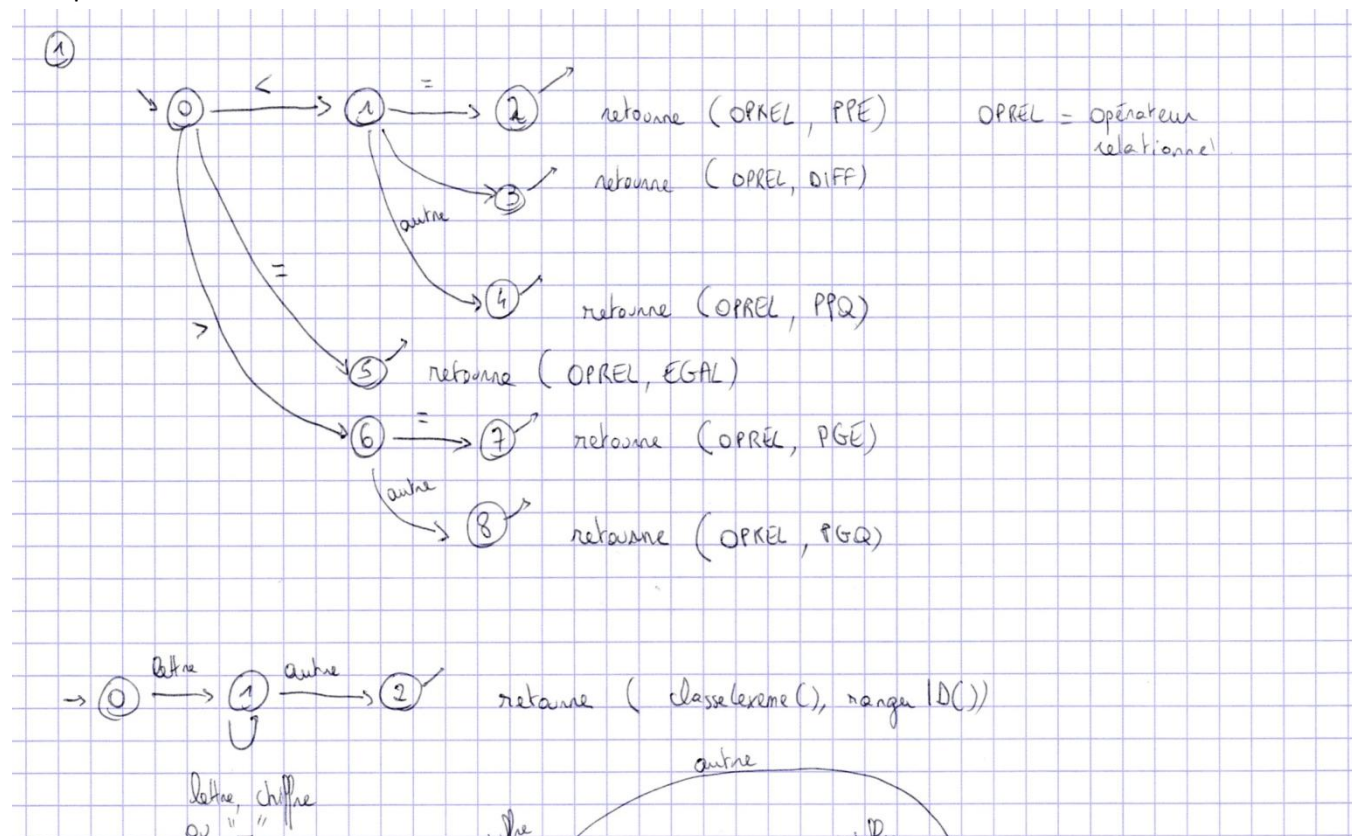



Figure 1

!! à « autre » : penser à renvoyer sur le flot de caractère le symbole lu (il appartient probablement au prochain lexème).



Ces automates sont à regrouper pour n'en faire plus qu'un, qu'il faut déterminer pour pouvoir l'utiliser comme support de détection des lexèmes.

L'analyseur lexical parcourt cet automate au fil des caractères lus sur l'entrée pour détecter les lexèmes.

Technique d'optimisation

- De la lecture
- De stockage (compression)

De l'automate


Technique de gestion d'erreurs.

Remarque : les lexèmes repérés doivent être les plus longs possibles

3.14

._.X

Remarque : ce module est le plus gourmand en temps, à cause des Entrées/sorties (à optimiser).



Algorithme de gestion des pointeurs :

Si avant est à la fin de la 1^{ère} moitié alors

Changer la 2^{nde} moitié

Avant <- avant + 1

Sinon

Si avant est à la fin de la 2^{nde} moitié alors

Changer la 1^{ère} moitié

Déplacer avant au début de la 1^{ère} moitié

Sinon

Avant <- avant + 1

Fin si

Fin si

Chapitre 4 : Analyse syntaxique

(début 18/09/2013, 25/09/2013, 02/10/2013, 16/10/2013 fin : 16/10/2013)


Deux grandes catégories :

- Analyseurs descendants (plus faciles à appréhender)
- Analyseurs ascendants (plus puissants).

4.1 Analyse descendante

Un analyseur descendant fonctionne selon le mécanisme du traducteur (chapitre 2).

On en présente ici une version non récursive. Plutôt que de générer une pile d'appels récursifs correspondant aux nœuds de l'arbre syntaxique en cours de construction et parcourus en ordre préfixe nous allons gérer explicitement la pile des symboles étiquetant ces nœuds.



- Tampon d'entrée : flot d'unités lexicales (terminé par un symbole spécial : \$)
- Pile de symboles grammaticaux : permet de gérer le parcours en profondeur
- Table d'analyse : contient les infos qui permettent à l'analyseur de choisir la production à utiliser à chaque étape selon l'unité lexicale.
- Sortie : l'analyseur peut produire une sortie à chaque étape. Nous nous contenterons de produire la production utilisée.

Ex :

$E \rightarrow T E'$

$E' \rightarrow + T E' \mid \epsilon$

$T \rightarrow F T'$

$T' \rightarrow * F T' \mid \epsilon$

$F \rightarrow (E) \mid id$

Algo : analyse descendante non récursive

Données : une chaîne **w** et une table d'analyse **M** pour une grammaire **G**.

Résultat : une dérivation gauche pour le mot **w** si $w \in L(G)$, une indication d'erreur sinon.

Initialisation :

- \$\$ dans la pile
- w\$ dans la pile

Positionner un pointeur source ps sur le 1^{er} symbole de w\$.

Répéter :

Soit X le symbole en sommet de pile et a le symbole repéré par ps.

Si X est un terminal ou \$ alors

Si X = a alors

défiler(X)

avancer(ps)

Sinon

Erreur()

Fin si

Sinon

Si $M[X, a] = X \rightarrow Y_1 Y_2 \dots Y_n$ alors

Défiler(X)

Empiler(Y_k, Y_{k-1}, \dots, Y_1) (avec Y1 au sommet)

Emettre($X \rightarrow Y_1 Y_2 \dots Y_k$)

Sinon

Erreur()

Finsi

Jusqu'à X = \$

Id + id * id

(Associé au schéma 1 du 25/09)

<u>Pile</u>	<u>Entrée</u>	<u>Sortie</u>
\$E	id + id * id\$	
\$E'T	id + id * id\$	E -> TE'
\$E'T'F	id + id * id\$	T -> FT'
\$E'T' id	id + id * id\$	F -> id
\$E'T'	+ id * id\$	
\$E'	+ id * id\$	T' -> ε
\$E'T+	id * id\$	E' -> TE'
\$E'T	id * id\$	
\$E'T'F	id * id\$	T -> FT'
\$E'T' id	id * id\$	F -> id
\$E'T	* id\$	
\$E'T'F*	*id\$	T' -> *FT'
\$E'T'F	id\$	
\$E'T' id	id\$	F -> id
\$E'T'	\$	
\$E'	\$	T' -> ε
\$	\$	E' -> ε
/	/	

4.2 Grammaire LL(1)

Pour remplir la table d'analyse, on s'appuie sur 2 fonctions associées à la grammaire : PREMIER et SUIVANT.

Etant donné une grammaire $G = \langle N, T, P, S \rangle$ et une production $A \rightarrow \alpha$ appartenant à P , la fonction PREMIER doit permettre de dire s'il est pertinent ou non de dériver A en α à la vue d'un symbole A .

Il s'agit donc d'une fonction définie de P vers $P(T)$. que nous construisons par extension successives du domaine de définition :

- 1/ PREMIER : $N \cup T \rightarrow P(T)$
- 2/ PREMIER : $(N \cup T)^* \rightarrow P(T \cup \{\epsilon\})$
- 3/ PREMIER : $P \rightarrow P(T \cup \{\epsilon\})$

1. LA 1^{ère} version à tout symbole X de la grammaire l'ensemble des symboles terminaux qui se trouvent en tête d'au moins une phrase dérivée de X .

Fonction préliminaire (déterminant les symboles effaçables de G).

EFFACABLE $\leftarrow \emptyset$

Répéter

Pour toute production $A \rightarrow \alpha$ faire

Si tous les symboles de α sont déjà dans EFFACABLE ou si $\alpha = \epsilon$ alors

Mettre A dans EFFACABLE

Finsi

Fin pour

Jusqu'à stabilisation de EFFACABLE

Algorithme de point fixe, qui termine car N est fini.

Pour tout symbole X de la grammaire faire

Si X est terminal alors

PREMIER(X) = { X }

Sinon

PREMIER(X) = \emptyset

Fin si

Fin pour

Répéter

Pour toute production $A \rightarrow X_1 \dots X_k$ (avec $k \geq 1$) faire

Ajouter PREMIER(X_i) à PREMIER(A) pour tout i tel que $\{X_1, \dots, X_{i-1}\} \subseteq \text{EFFACABLE}$

Fin pour

Jusqu'à stabilisation de tous les ensembles PREMIER.

Algorithme de point fixe qui termine car T est fini.

2. $\text{PREMIER}(\epsilon) = \{\epsilon\}$

$\text{PREMIER}(X\alpha) = \text{PREMIER}(\text{version 1}) (X) \cup Q$

Où $Q = \text{PREMIER}(\alpha)$ si X est Effaçable

\emptyset sinon

3. Expression triviale :

$\text{PREMIER}(A \rightarrow \alpha) = \text{PREMIER}(\text{version 2}) (\alpha)$

Exemple :

$E \rightarrow T E'$

$E' \rightarrow + T E' \mid \epsilon$

$T \rightarrow F T'$

$T' \rightarrow * F T' \mid \epsilon$

$F \rightarrow (E) \mid \text{id}$

$\Rightarrow \text{EFFACABLE} = \{E', T'\}$

$\text{PREMIER}(+) = \{+\}$

$\text{PREMIER}(*) = \{*\}$

$\text{PREMIER}(() = \{(\}$

$\text{PREMIER}() = \{ \}$

$\text{PREMIER}(\text{id}) = \{\text{id}\}$

$\text{PREMIER}(E) = \{ (, \text{id} \}$

$\text{PREMIER}(E') = \{ + \}$

$\text{PREMIER}(T) = \{ (, \text{id} \}$

$\text{PREMIER}(T') = \{ * \}$

$\text{PREMIER}(F) = \{ (, \text{id} \}$

$\text{PREMIER}(E \rightarrow T E') = \{ (, \text{id} \}$

$\text{PREMIER}(E' \rightarrow + T E') = \{ + \}$

$\text{PREMIER}(E' \rightarrow \epsilon) = \{ \epsilon \}$

$\text{PREMIER}(T \rightarrow F T') = \{ (, \text{id} \}$

PREMIER ($T' \rightarrow * F T'$) = { (, id }

PREMIER ($T' \rightarrow \epsilon$) = { ϵ }

PREMIER ($F \rightarrow (E)$) = { (}

PREMIER ($F \rightarrow id$) = { id }

$S \rightarrow A \mid BD$

$A \rightarrow \epsilon \mid aB \mid aA$

$B \rightarrow bB \mid ADe$

$D \rightarrow AA \mid dD \mid dS$

EFFACABLE = {A, D, S}

PREMIER(S) = {a, b, e, d}


PREMIER(A) = {a}

PREMIER(B) = {b, a, e, d}

PREMIER(D) = {a, d}

La fonction SUIVANT détermine pour chaque symbole non-terminal A, l'ensemble des symboles terminaux susceptibles de suivre A dans une proto-phrasé issue de l'axiome.

SUIVANT(A) est l'ensemble des symboles a pour lesquels il existe une dérivation de la forme $S \xrightarrow{*} \alpha A a \beta$



Pour tout non-terminal A de la grammaire faire

SUIVANT(A) = \emptyset

Fin pour

SUIVANT(S) = { S }

Pour toute production $A \rightarrow \alpha B \beta$ faire

Ajouter $\text{PREMIER}(\beta) \setminus \{\epsilon\}$ à SUIVANT(B)

Fin pour

Repéter

Pour toute production $A \rightarrow \alpha B \beta$ avec $\epsilon \in \text{PREMIER}(\beta)$ faire

Ajouter SUIVANT(A) à SUIVANT(B)

Fin pour

Jusqu'à stabilisation de tous les ensembles.

SUIVANT(E) = { \$,) }

SUIVANT(E') = { \$,) }

SUIVANT(T) = { +, \$,) }

SUIVANT(T') = { +, \$,) }

SUIVANT(F) = { *, +, \$,) }

$S \rightarrow A \mid BD$
 $A \rightarrow \varepsilon \mid aB \mid aA$
 $B \rightarrow bB \mid Ade$
 $D \rightarrow AA \mid dD \mid dS$
 $\text{EFFACABLE} = \{ S, A, D \}$
 $\text{PREMIER}(S) = \{ a, b, d, e \}$
 $\text{PREMIER}(A) = \{ a \}$
 $\text{PREMIER}(B) = \{ b, a, e, d \}$
 $\text{PREMIER}(D) = \{ a, d \}$
 $\text{SUIVANT}(S) = \{ \$, e \}$
 $\text{SUIVANT}(A) = \{ a, d, e, \$ \}$
 $\text{SUIVANT}(B) = \{ a, d, \$, e \}$
 $\text{SUIVANT}(D) = \{ e, \$ \}$

Algo : Remplissage d'une table d'analyse descendante

Donnée : Une grammaire G

Résultat : une table d'analyse M pour G.

Pour chaque production $A \rightarrow \alpha$ de G faire

Pour chaque terminal a de $\text{PREMIER}(\alpha)$ faire

 Ajouter $A \rightarrow \alpha$ à $M[A, a]$

Fin pour

Si $\varepsilon \in \text{PREMIER}(\alpha)$ alors

Pour chaque symbole b de $\text{SUIVANT}(A)$ faire

 Ajouter $A \rightarrow \alpha$ à $M[A, b]$

Fin pour

Fin si

Fin pour

$\text{EFFACABLE} + \{ E', T' \}$

 $E \rightarrow T E'$
 $\text{PREMIER}(E) = \{ (, id \}$
 $\text{SUIVANT}(E) = \{ \$,) \}$
 $E' \rightarrow + T E' \mid \varepsilon$
 $\text{PREMIER}(E') = \{ + \}$
 $\text{SUIVANT}(E') = \{ \$,) \}$
 $T \rightarrow F T'$
 $\text{PREMIER}(T) = \{ (, id \}$
 $\text{SUIVANT}(T) = \{ +, \$,) \}$
 $T' \rightarrow * F T' \mid \varepsilon$
 $\text{PREMIER}(T') = \{ * \}$
 $\text{SUIVANT}(T') = \{ +, \$,) \}$
 $F \rightarrow (E) \mid id$
 $\text{PREMIER}(F) = \{ (, id \}$
 $\text{SUIVANT}(F) = \{ *, +, \$,) \}$

	id	+	*	()	\$
E	$E \rightarrow T E'$			$E \rightarrow T E'$		
E'		$E' \rightarrow T E'$			$E' \rightarrow \varepsilon$	$E' \rightarrow \varepsilon$
T	$T \rightarrow F T'$			$T \rightarrow F T'$		
T'		$T' \rightarrow \varepsilon$	$T' \rightarrow * F T'$		$T' \rightarrow \varepsilon$	$T' \rightarrow \varepsilon$
F	$F \rightarrow id$			$F \rightarrow (E)$		

Une telle table n'est utilisable pour réaliser une analyse descendante que si elle ne contient pas d'entrée multiples.

Une grammaire :

- Ambigüe
 - Récursive à gauche
 - Ou non factorisée à gauche
- produit toujours une entrée multiple.

Définition : une grammaire algébrique dont la table d'analyse descendante ne contient pas d'entrée multiple est dite LL(1). (L pour Left, le 1^{er} left est pour entrée lue de gauche à droite, le deuxième est la position d'une dérivation gauche et le 1 est le nombre de symbole(s) de prévision).

Exemple classique de grammaire non LL(1).

$S \rightarrow i E t S S' \mid a$

$S' \rightarrow e S \mid \epsilon$


$E \rightarrow b$

PREMIER (S) = { i, a }	SUIVANT(S) = { \$, e }
PREMIER(S') = { e }	SUIVANT(S') = { \$, e }
PREMIER(E) = { b }	SUIVANT(E) = { t }
EFFACABLE = { S' }	

	a	b	e	i	t	\$
S	$S \rightarrow a$		$S \rightarrow i E t S S'$			
S'		$S' \rightarrow e S$ $S' \rightarrow \epsilon$				$S' \rightarrow \epsilon$
E		$E \rightarrow b$				

Schéma 1 :

i b t i b t a e a



Solutions possibles :

- Chercher une grammaire équivalente non ambiguë (il en existe une, ici).
- Forcer le conflit en retenant $S' \rightarrow eS$ quand on doit dériver S' à la vue d'un e (revient à choisir d'associer chaque else au then le plus proche, qui précède et qui n'est pas déjà associé à un else).
 - Possible ici, mais pas en général.

4.3 Analyse ascendante

Construction d'un arbre syntaxique des feuilles vers la racine. On va produire une dérivation droite inversée du texte source.

La classe des grammaires analysables sera notée LR. L'analyseur ascendant (encore appelée analyseur décalage – réduction) consiste en une suite d'étapes permettant de réduire une chaîne initiale en l'axiome de la grammaire. A chaque étape un facteur correspondant à la partie droite d'une production est réduit en le symbole à gauche de cette production.

$S \rightarrow aAE$

$A \rightarrow aA \mid Bd \mid aB$

$B \rightarrow b$

$E \rightarrow e$

$\omega = a a \underline{b} d c \xrightarrow{\text{réduction}} a a \underline{B} d e \xrightarrow{\text{réduction}} a \underline{aA} e \xrightarrow{\text{réduction}} a \underline{A} e \xrightarrow{\text{réduction}} a \underline{AE} \xrightarrow{\text{réduction}} S$

On peut faire de mauvais choix.

$\omega = a a \underline{b} d c \xrightarrow{\text{réduction}} a \underline{aB} d e \xrightarrow{\text{réduction}} a \underline{A} d e \xrightarrow{\text{réduction}} A d e \xrightarrow{\text{réduction}} A d E$

$\omega = a a \underline{b} d c \xrightarrow{\text{réduction}} a a \underline{B} d e \xrightarrow{\text{réduction}} a \underline{aA} e \xrightarrow{\text{réduction}} a \underline{A} e \xrightarrow{\text{réduction}} A \underline{e} \xrightarrow{\text{réduction}} A E$

Définition : on appelle manche d'une proto-phrase droite γ toute production $A \rightarrow \beta$ associée à une position γ où β peut être trouvée et remplacée par A pour produire la proto-phrase droite précédente dans une dérivation droite de γ .

$S \xrightarrow{*} (d) \alpha A v \xrightarrow{d} \alpha \beta v$

La production $A \rightarrow \beta$ dans la position suivant α est un manche de $\alpha \beta v$.

Remarque :

- i) V ne contient que des symboles terminaux.
- ii) Une proto-phrase peut posséder plusieurs manches auquel cas il lui correspond plusieurs dérivations droites, ce qui signifie que la grammaire est ambiguë.


Ex : $E \rightarrow E + E \mid E * E \mid (E) \mid id$

$\omega = id + id * id$

$E \rightarrow \underline{E + E}$	$E \rightarrow \underline{E * E}$
$\rightarrow E + \underline{E * E}$	$\rightarrow E * \underline{id}$
$\rightarrow E + E * \underline{id}$	$\rightarrow \underline{E + E} * id$
$\rightarrow E + \underline{id} * id$	$\rightarrow E + \underline{id} * id$
$\rightarrow \underline{id} + id * id$	$\rightarrow \underline{id} + id * id$

<- 2 manches différents ->

Représentation schématique d'un manche :



A est le symbole non-terminal le plus à droite de αAv .

La prochaine étape consiste à réduire β en A (élagage de manche).

Etape d'une analyse ascendante :


- 1) On dispose la phrase à analyser dans un tampon d'entrée.
- 2) On décale un à un les symboles de tampon vers une pile.
- 3) Chaque fois qu'un manche apparaît au sommet de la pile, on la réduit.
- 4) On s'arrête lorsque le tampon est vide et que la pile contient l'axiome (succès) ou lorsque les symboles grammaticaux situés en sommet de pile n'ont aucune chance de contribuer à l'apparition d'un manche (erreur).

09/10/2013

$E \rightarrow E + E \mid E * E \mid (E) \mid id$

$\omega = id + id * id$

<u>Pile</u>	<u>Entrée</u>	<u>Actions</u>
\$	id + id * id\$	décale
\$id	+ id * id\$	réduire par $E \rightarrow id$
\$E	+ id * id\$	décaler
\$E +	id * id\$	décaler
\$E + id	* id\$	réduire par $E \rightarrow id$
\$E + E	id\$	décaler
\$E + E *	id\$	décaler
\$E + E * id	\$	réduire par $E \rightarrow id$
\$E + E * E	\$	réduire par $E \rightarrow E * E$
\$E + E	\$	réduire par $E \rightarrow E + E$
\$E	\$	accepter



$E \rightarrow E + E \rightarrow E + E * E \rightarrow E + E * id \rightarrow E + id * id \rightarrow id + id * id$

$\omega = (id +) * id$

<u>Pile</u>	<u>Entrée</u>	<u>Actions</u>
\$	(id+)*id\$	décaler
\$ (id+)*id\$	décaler
\$ (id	+) *id\$	réduire $E \rightarrow id$
\$ (E	+) *id\$	décaler
\$ (E+) *id\$	erreur

Impossible de réduire, pas de manche en sommet de pile.

Inutile de décaler (E+) n'est pas un préfixe viable.

Définition : Un préfixe viable est un préfixe d'une proto-phrase droite qui ne s'étend pas au-delà de l'extrémité droite du manche le plus à droite de cette proto-phrase.

Remarque : Ce sont exactement les préfixes qui peuvent apparaître sur la pile d'un analyseur par décalage-réduction.

En théorie : chaque étape d'une analyse ascendante consiste à repérer un manche pour la réduire.

En pratique : ce n'est pas toujours possible automatiquement. Il est impossible de repérer un manche de façon sûre pour une grammaire quelconque quand on ne possède qu'un préfixe de proto-phrase droite.

Seule une sous-classe des grammaires algébriques pourra être traitée.

Quand on traitera une grammaire n'appartenant pas à cette classe :

- Conflits réduire / décaler
- Conflits réduire / réduire

Technique LR(k)

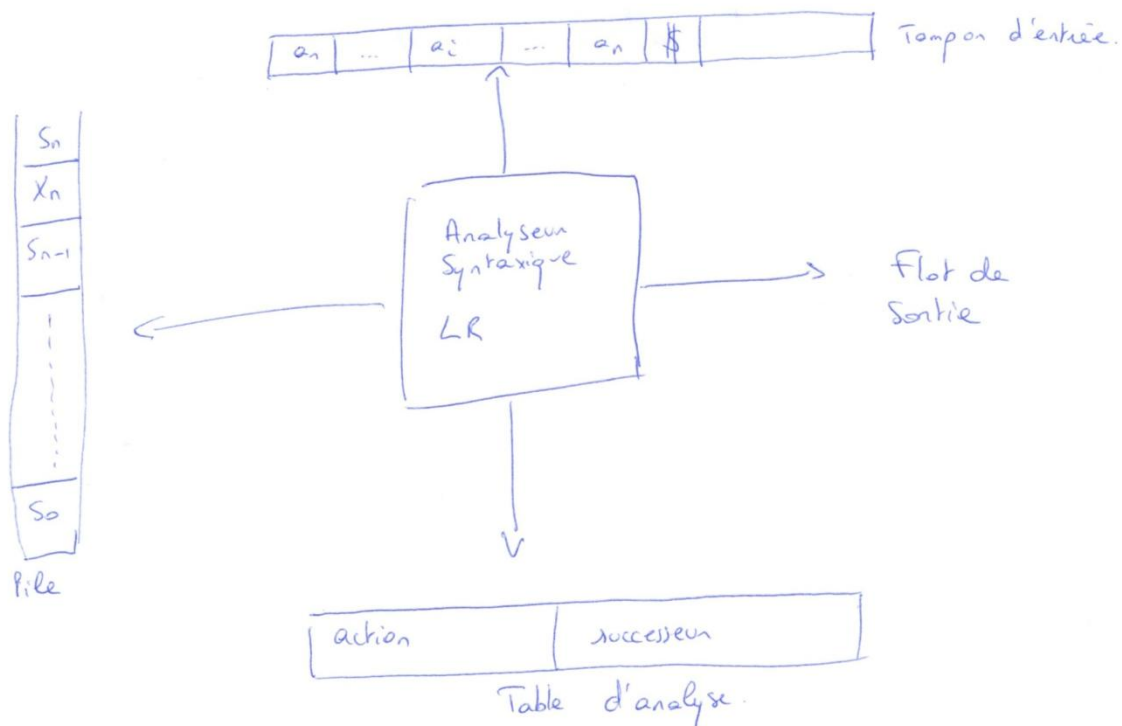
L \rightarrow Left (Flot de lexèmes ratés de gauche à droite)

R \rightarrow Right (Construction d'une dérivation droite).

k \rightarrow nombre de symboles de pré-vision (k = 1, ici).

a1	...	ai	...	an	\$	
----	-----	----	-----	----	----	--

Tampon d'entrée



Les unités sont lues unes à unes pour produire en sortie la dérivation droite de la chaîne d'entrée à l'aide d'une pile. Dans celle-ci, sont intercalés les états d'un automate entre les symboles grammaticaux. Cet automate reconnaît les préfixes viables de la grammaire (pour toute grammaire algébrique, le langage de ses préfixes viables est rationnel). En pratique, seuls les états de l'automate sont utiles dans la pile. On y fait apparaître les symboles grammaticaux pour une meilleure visibilité des algorithmes.

Tables d'analyses :

- Actions : détermine s'il faut réduire ou décaler
- Successeur : détermine l'état à placer en sommet de pile après une réduction.

	Action						Successeur		
	id	+	*	()	\$	E	T	F
0	d5			d4			1	2	3
1		d6				acc			
2		r2	d7		r2	r2			
3		r4	r4		r4	r4			
4	d5			d4			8	2	3
5		r6	r6		r6	r6			
6	d5			d4				9	3
7	d5			d4					10
8		d6			d11				
9		r1	d7		r1	r1			
10		r3	r3		r3	r3			
11		r5	r5		r5	r5			

Algorithme Analyse LR

Données : Une chaîne w et une table d'analyse LR pour une grammaire G

Résultat : une dérivation droite inversée pour w si $w \in L(G)$ une indication d'erreur, sinon.

Initialisation :

- A_0 dans la pile
 - $w\$$ dans le tampon
- positionner le pointeur source ps sur le 1^{er} symbole de $w\$$

répéter indéfiniment

$s \leftarrow$ sommet de la pile

$a \leftarrow$ symbole pointé par ps

si ($\text{action}[s, a] = \text{décaler } s'$) alors

empiler(a)

empiler(s') (s' est un état quelconque)

incrémenter(ps)

sinon

si ($\text{action}[s, a] = \text{réduire par } A \rightarrow \beta$) alors

dépiler $2 * |\beta|$ symboles

$s' \leftarrow$ sommet de la pile

empiler(A)

empiler($\text{successeur}[s', A]$)

émettre($A \rightarrow \beta$)

sinon

si ($\text{action}[s, a] = \text{accepter}$) alors

fin()

sinon

erreur()

fin si

fin si

fin si

fin répéter

Ex :

$E \rightarrow E + T$ (1)

$E \rightarrow T$ (2)

$T \rightarrow T * F$ (3)

$T \rightarrow F$ (4)

$F \rightarrow (E)$ (5)

$F \rightarrow \text{id}$ (6)

<u>Pile</u>	<u>Entrée</u>	<u>Actions</u>
0	id + id * id\$	décaler
0id5	+ id * id\$	réduire par $F \rightarrow id$
0F3	+ id * id\$	réduire par $T \rightarrow F$
0T2	+ id * id\$	réduire par $E \rightarrow T$
0E1	+ id * id\$	décaler
0E1+6	id * id\$	décaler
0E1+6id5	* id\$	réduire par $F \rightarrow id$
0E1+6F3	* id\$	réduire par $T \rightarrow F$
0E1+6T9	* id\$	décaler
0E1+6T9*7	id\$	décaler
0E1+6T9*7id5	\$	réduire par $F \rightarrow id$
0E1+6T9*7F10	\$	réduire par $T \rightarrow T * F$
0E1+6T9	\$	réduire par $E \rightarrow E + T$
0E1	\$	accepter

Il nous reste à voir comment remplir les tables action et successeur (nécessitent l'automate des préfixes viables).

Définition : on appelle item d'une grammaire G , toute production de G à l'intérieur de laquelle une position est marquée dans sa partie droite.

Ex : $A \rightarrow XYZ$

Fournit 4 items.

$$\left\{ \begin{array}{l} A \rightarrow .XYZ \\ A \rightarrow X.YZ \\ A \rightarrow XY.Z \\ A \rightarrow XYZ. \end{array} \right.$$

$A \rightarrow \varepsilon$

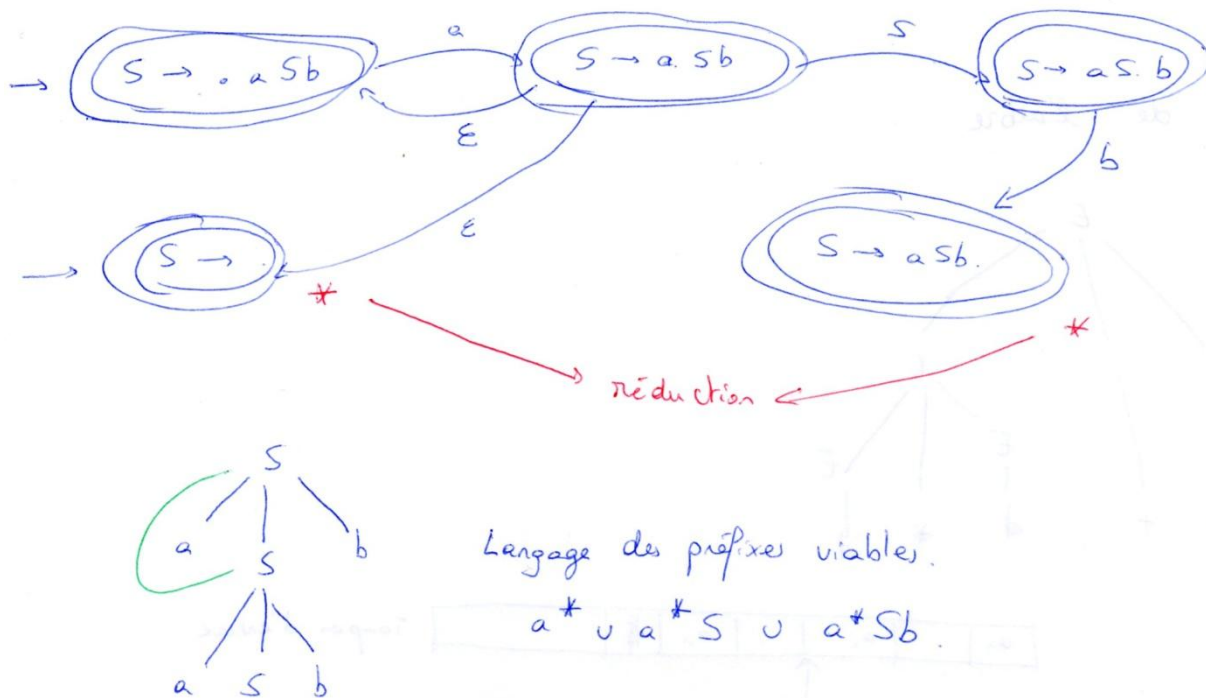
Fournit 1 item. $A \rightarrow .$

Intuitivement, les items permettent de repérer la « quantité » de partie droite d'une production déjà reconnue par l'analyseur.

L'ensemble des items d'une grammaire G constitue l'ensemble des états d'un AFN (Automate Fini non déterministe) reconnaissent les préfixes viables de cette grammaire.

$S \rightarrow aSb \mid \varepsilon$

Schéma 4.



$S \rightarrow aSb \rightarrow aaSbb \rightarrow aaaSbbb \rightarrow \dots \rightarrow aaa \dots a \text{ (nb de } a : n-1) S b \mid bbbbbb \dots b \text{ (nb de } b = n-1) \rightarrow a \dots a(n) \mid b \dots b(n)$

Préfixes viables.

16/10/2013

Définition : Si G est une grammaire d'axiome S , on note G' la grammaire augmentée de G obtenue en ajoutant à G un nouvel axiome S' et une production supplémentaire $S' \rightarrow S$

L'opération de fermeture

I : ensemble d'items \rightarrow Fermeture(I) : ensemble d'items

Fermeture(I) $\leftarrow I$

Repéter

Pour tout item de Fermeture(I) de la forme $A \rightarrow \alpha.B\beta$ faire

Pour toute production $B \rightarrow \gamma$ faire

Ajouter $B \rightarrow \gamma$ à Fermeture(I)

Fin pour

Fin pour

Jusqu'à stabilisation de l'ensemble

Ex :

$E' \rightarrow E$

$E \rightarrow E + T \mid T$

$T \rightarrow T * F \mid F$

$F \rightarrow (E) \mid id$

$I = \{E' \rightarrow \cdot E\}$

Fermeture(I) = $\{E' \rightarrow \cdot E, E \rightarrow \cdot E + T, E \rightarrow \cdot T, T \rightarrow \cdot T * F, T \rightarrow \cdot F, F \rightarrow \cdot (E), F \rightarrow \cdot id\}$

L'opération de Transition

Si I est un ensemble d'items et X un symbole de G alors $\text{Transition}(I, X)$ est définie comme fermeture de l'ensemble de tous les items de la forme $A \rightarrow \alpha.X\beta$ appartenant à I

Exemple :

$$I = \{ E \rightarrow T., T \rightarrow T.*F \}$$

$$\text{Transition}(I, *) = \{ T \rightarrow T*.F, F \rightarrow .(E), F \rightarrow \text{id} \}$$

Algorithme Ensemble d'items

Données Une grammaire augmentée G'

Résultat Une collection d'ensembles d'items correspondant aux états de l'automate fini déterministe (AFD) reconnaissant les préfixes viables de G' .

$C \leftarrow \text{Fermeture}(\{S' \rightarrow .S\})$

Répéter

Pour tout ensemble d'items I de C faire

Pour tout symbole X de G faire

Si $\text{Transition}(I, X) \neq \emptyset$ alors

 Ajouter $\text{Transition}(I, X)$ à C


Fin si

Fin pour

Fin pour

Jusqu'à stabilisation de C

Schéma 1.



Reconnait les préfixes viables quand tous les états sont terminaux.

$I_0 E' \rightarrow .E$
 $E \rightarrow .E + T$
 $E \rightarrow .T$
 $E \rightarrow .T * F$
 $T \rightarrow .F$
 $F \rightarrow .(E)$
 $F \rightarrow .id$
 $I_1 E' \rightarrow E.$

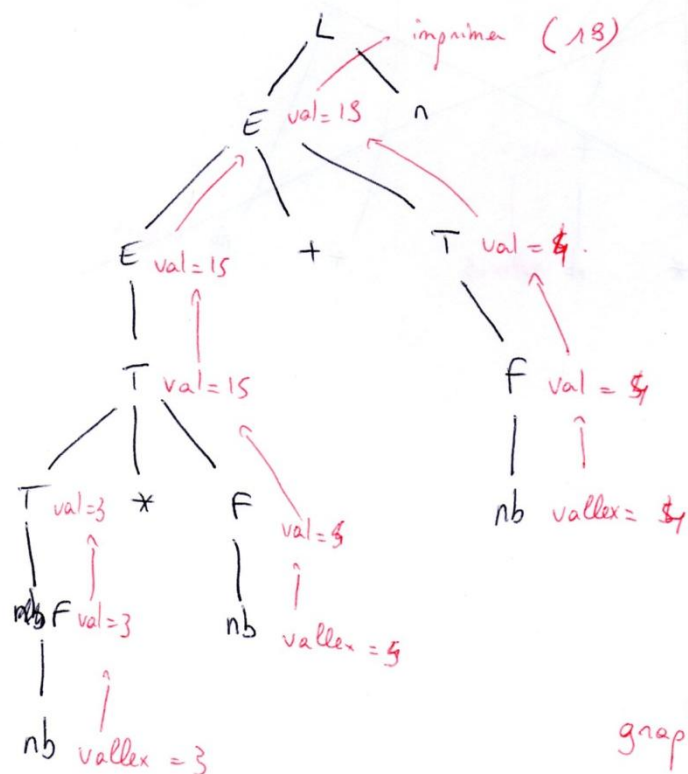
I_6
 $E \rightarrow E + .T$
 $T \rightarrow .T * F$
 $T \rightarrow .F$
 $F \rightarrow .(E)$
 $F \rightarrow .id$

I_7

$E \rightarrow E.+T$	$T \rightarrow T*.F$
$I_2 E \rightarrow T.$	$F \rightarrow .(E)$
$T \rightarrow T.*F$	$F \rightarrow .id$
$I_3 T \rightarrow F.$	I_8
I_4	$F \rightarrow (E.)$
$F \rightarrow (.E)$	$E \rightarrow E.+T$
$E \rightarrow .E+T$	I_9
$E \rightarrow .T$	$E \rightarrow E+T.$
$T \rightarrow .F$	$T \rightarrow T.*F$
$F \rightarrow .(E)$	
$F \rightarrow .id$	I_{10}
I_5	$T \rightarrow T * F.$
$F \rightarrow id.$	I_{11}
	$F \rightarrow (E).$

Schéma 2:

$3 * 5 + 4 n$



graphe de dépendances.

Algorithme Construction d'une table d'analyse LR

Données une grammaire augmentée G'

Résultat Les tables Action et Successeur de G'

Construire $C = \{I_0, \dots, I_n\}$ la collection d'ensemble d'items pour G'

Pour i allant de 0 à n faire

 Pour tout symbole X de G' faire

 Si $\text{Transition}(X_i, X) = I_j$ alors

 Si X est terminal alors

 Mettre « décaler j » dans $\text{Action}[i, X]$

 Sinon

 Mettre « j » dans successeur $[i, X]$

 Fin si

 Fin si

Fin pour

Pour tout item $A \rightarrow \alpha. \in I_i$ faire

 Pour tout $a \in \text{SUIVANT}(A)$ faire

 Mettre « réduire par $A \rightarrow \alpha$ » dans $\text{Action}[i, a]$

 Fin pour

Fin pour

Si $S' \rightarrow S. \in I_i$ alors

 Mettre « accepter » dans $\text{Action}[i, \$]$

Fin si

Fin pour

PREMIER ET SUIVANT

	Action						Successeur		
	id	+	*	()	\$	<i>E</i>	<i>T</i>	<i>F</i>
0	d5			d4			1	2	3
1		d6				acc			
2		r2	d7		r2	r2			
3		r4	r4		r4	r4			
4	d5			d4			8	2	3
5		r6	r6		r6	r6			
6	d5			d4				9	3
7	d5			d4					10
8		d6			d11				
9		r1	d7		r1	r1			
10		r3	r3		r3	r3			
11		r5	r5		r5	r5			

Chapitre 5 : Traduction dirigée par la syntaxe (début 16/10/2013 – fin)

Parcourir l'arbre syntaxique autant de fois que nécessaire pour évaluer les règles sémantiques du langage à ses nœuds.

Remarque : Cette phase d'analyse sémantique n'est pas nécessaire dissociée de la phase d'analyse syntaxique, l'arbre syntaxique peut même ne pas être construit explicitement.

5.1 Attributs

On associe des attributs aux symboles grammaticaux. Ils représentent des informations liées aux symboles telles que nombre, types, adresses mémoires, ...

L'évaluation des attributs sur un arbre syntaxique est un processus appelé « décoration ». Il est réalisé selon les règles sémantiques du langage qui supposent des dépendances entre attributs (décrites par un graphe de dépendances).

2 types d'attributs :

- Les attributs synthétisés dont la valeur dépend de celles des attributs aux fils du nœud considéré.
- Les attributs hérités dont la valeur dépend de celles des attributs au père et aux frères du nœud considéré.

Formellement : dans une définition dirigée par la syntaxe chaque production $A \rightarrow \alpha$ possède un ensemble de règles sémantiques de la forme $b \leftarrow f(c_1, \dots, c_k)$ où f est une fonction, b est soit un attribut synthétisé de A , soit un attribut hérité d'un symbole de α et c_1, \dots, c_k sont des attributs de symboles quelconques de la production.

Exemple :

Productions	Règles sémantiques
$L \rightarrow E n$	$\text{imprimer}(L.\text{val})$
$E \rightarrow E_1 + T$	$E.\text{val} \leftarrow E_1.\text{val} + T.\text{val}$
$E \rightarrow T$	$E.\text{val} \leftarrow T.\text{val}$
$T \rightarrow T_1 * F$	$T.\text{val} \leftarrow T_1.\text{val} * F.\text{val}$
$T \rightarrow F$	$T.\text{val} \leftarrow F.\text{val}$
$F \rightarrow (E)$	$F.\text{val} \leftarrow E.\text{val}$
$F \rightarrow nb$	$F.\text{val} \leftarrow nb.\text{vallex}$

23/10/2013

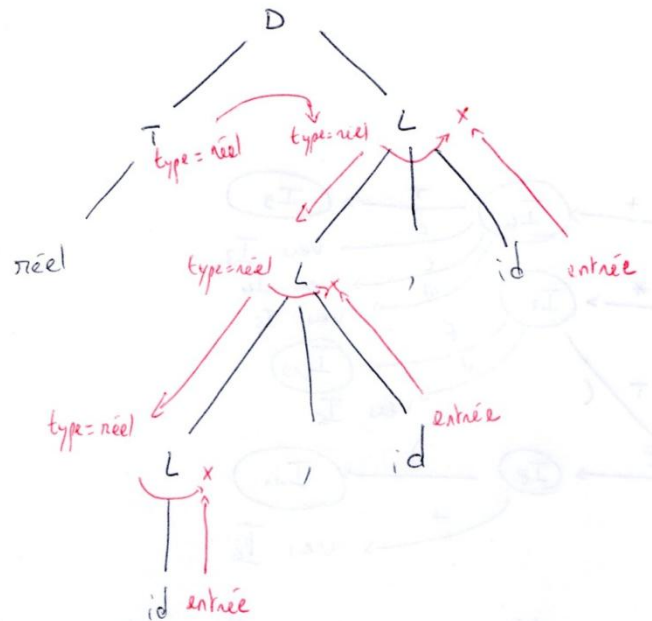
Définition : une définition dirigée par la syntaxe n'utilisant que des attributs synthétisés est appelée une définition « S-attribuée ».

Remarque : Il est toujours possible de se ramener à une définition S-attribuée mais on peut perdre en intuition. Il est souvent plus naturel d'employer des attributs hérités.

Ex :

Productions	Règles sémantiques
$D \rightarrow TL$	$L.type \leftarrow T.type$
$T \rightarrow entier$	$T.type \leftarrow entier$
$T \rightarrow réel$	$T.type \leftarrow réel$
$L \rightarrow L_1, id$	$L_1.type \leftarrow L.type$
$L \rightarrow id$	$ajouter_type(id.entrée, L.type)$
	$ajouter_type(id.entrée, L.type)$

Schéma 1.
réel id, id, id



Une règle sémantique peut induire des effets de bord. Lorsqu'elle ne sert qu'à cela (cf. `ajouter_type`) on lui associe un attribut factice qui apparaît dans le graphe de dépendances. Ceci afin d'insérer l'appel à cette fonction dans le traducteur qui sera déduit de la définition dirigée par la syntaxe. L'ordre dans lequel sont évalués les attributs dépend des contraintes décrites par le graphe de dépendances.

Si ces contraintes ne sont pas contredites, l'ordre peut être induit par l'analyse syntaxique.

Seule impossibilité : cycle dans le graphe de dépendances.

Il existe des algorithmes (peu efficaces) pour tester la non-circularité des graphes de dépendances associés à une définition dirigée par la syntaxe.

Nous ne les étudierons pas et nous limiterons à des définitions compatibles avec les analyses LL et/ou LR.

5.2 Définitions S-attribuées

Attribut synthétisé \rightarrow évalués des feuilles vers la racine.

A priori compatible avec un parcours suffixe (or l'anal. LR produit les nœuds précisément dans cet ordre).

Il suffit de gérer une pile d'attributs en parallèle avec la pile d'anal. synt. Pour une analyse LR.

Pour une analyse LL les nœuds sont générés en ordre préfixe. L'astuce consistera à laisser une post-it dans la pile pour mémoriser le fait qu'un attribut reste à calculer après le traitement de tous les fils d'un nœud.

5.2.1 Analyse ascendante

Schéma de traduction :

$L \rightarrow E \text{ n } \{ \text{imprimer(sommet()) ; dépiler()} \}$

$E \rightarrow E + T \{ \text{op2} \leftarrow \text{sommet()} ; \text{dépiler()} ; \text{op1} \leftarrow \text{sommet()} ; \text{dépiler()} ; \text{empiler}(\text{op1} + \text{op2}) \}$

$E \rightarrow T$


$T \rightarrow T * F \{ \text{op2} \leftarrow \text{sommet()} ; \text{dépiler()} ; \text{op1} \leftarrow \text{sommet()} ; \text{dépiler()} ; \text{empiler}(\text{op1} * \text{op2}) \}$

$T \rightarrow F$

$F \rightarrow (E)$

$F \rightarrow \text{nb}$

Pile d'analyse	Pile d'attributs	Entrée	Productions
		3 * 5 + 4n	
nb	3	* 5 + 4n	F -> nb
F	3	* 5 + 4n	T -> F
T	3	* 5 + 4n	
T *	3	5 + 4n	
T * nb	3 5	+ 4n	F -> nb
T * F	3 5	+ 4n	T -> T * F
T	15	+ 4n	E -> T
E	15	+ 4n	
E +	15	4n	
E + nb	15 4	n	F -> nb
E + F	15 4	n	T -> F
E + T	15 4	n	E -> E + T
E	19	n	
En	19	/	L -> En
L	/	/	



5.2.2 Analyse descendante

La grammaire est récursive gauche (pas d'anal desc possible) élimine la récursivité gauche ? Non ! (Apparition d'attributs hérités -> cf + loin).

Autre exemple : évaluateur d'expressions préfixes.

Production	Règles sémantiques
L -> En	imprimer(E.val)
L -> + E ₁ E ₂	E.val ← E ₁ .val + E ₂ .val
E -> * E ₁ E ₂	E.val ← E ₁ .val * E ₂ .val
E -> nb	E.val ← nb.vallex

Schéma de traduction correspondant :

L -> En { imprimer(sommet()) ; dépiler() ; } (0)

E -> + EE { op2 ← sommet() ; dépiler() ; op1 ← sommet() ; dépiler() ; empiler(op1 + op2) ; } (1)

E -> * EE { op2 ← sommet() ; dépiler() ; op1 ← sommet() ; dépiler() ; empiler(op1 * op2) ; } (2)


E -> nb

Table d'analyse LL :

	+	*	nb	n
L	L -> En	L -> En	L -> En	
E	E -> + EE	E -> *EE	E -> nb	

Pile d'analyse	Pile d'attributs	Entrée	Productions
L		+ * 3 5 4 n	L -> En
{0}n E		+ * 3 5 4 n	
{0}n {1} EE+		+ * 3 5 4 n	E -> + EE
{0}n {1} EE		* 3 5 4 n	E -> * EE
{0}n {1} E {2} EE *		* 3 5 4 n	
{0}n {1} E {2} EE		3 5 4 n	E -> nb
{0}n {1} E {2} Enb		3 5 4 n	
{0}n {1} E {2} E	3	5 4 n	E -> nb
{0}n {1} E {2} nb	3	5 4 n	
{0}n {1} E {2}	3 5	4 n	
{0}n {1} E	15	4 n	E -> nb
{0}n {1}	15 4	n	
{0}n	19	n	
{0}	19	/	
/	/	/	

Schema 3:



5.3 Définitions L-attribuées

(06/11/2013)

Quand des attributs hérités interviennent dans une définition il n'est pas toujours possible de réaliser une traduction dirigée par la syntaxe en parallèle avec l'analyse syntaxique.

Des définitions avec lesquelles cela reste souvent possible sont les définitions L-attribuées.

Définition : Une définition dirigée par la syntaxe est L-attribuée si tout attribut hérité de X_j dans la production $A \rightarrow X_1 \dots X_n$ ne dépend que :

- Des attributs de X_1, \dots, X_{j-1}
- Des attributs hérités de A .

Une définition L-attribuée permet encore de décorer un arbre en réalisant un parcours en profondeur à main gauche.

Les attributs semblent se propager depuis la gauche (vers la droite) -> d'où le « L ».

Toute définition S-attr. est L-attr.

5.3.1 Analyse descendante

On sait déjà gérer les attributs synth.

Les attributs hérités se propagent en suivant à peu près l'ordre dans lequel les nœuds sont produits lors d'une analyse LL => facile, en principe.

Une manipulation qui fait apparaître des attributs hérités à partir d'une définition basée sur une grammaire récursive gauche -> l'élimination de la rec. gauche :

$A \rightarrow A_1 Y \{A.a \leftarrow g(A_1.a, Y.y)\}$

$A \rightarrow X \{A.a \leftarrow f(X.x)\}$

$A \rightarrow X R \{ R.h \leftarrow f(X.x), A.a \leftarrow R.s \}$
 $R \rightarrow Y R_1 \{ R_1.h \leftarrow g(R.h, Y.y), R.s \leftarrow R_1.s \}$
 $R \rightarrow \varepsilon \{ R.s \leftarrow R.h \}$





Schéma 1



Ex :

$E \rightarrow E_1 + T \{ E.val \leftarrow E_1.val + T.val \}$

$E \rightarrow E_1 - T \{ E.val \leftarrow E_1.val - T.val \}$

$E \rightarrow T \{ E.val \leftarrow T.val \}$

$T \rightarrow (E) \{ T.val \leftarrow E.val \}$

$T \rightarrow nb \{ T.val \leftarrow nb.vallex \}$

Elimination de la récursivité gauche :

$E \rightarrow TE' \{ E'.h \leftarrow T.val, E.val \leftarrow E'.val \}$

$E' \rightarrow + TE'_1 \{ E'_1.h \leftarrow E'.h + T.val, E'.val \leftarrow E'_1.val \}$

$E' \rightarrow - TE'_1 \{ E'_1.h \leftarrow E'.h - T.val, E'.val \leftarrow E'_1.val \}$

$E' \rightarrow \varepsilon \{ E'.val \leftarrow E'.h \}$

$T \rightarrow (E) \{ T.val \leftarrow E.val \}$

$T \rightarrow nb \{ T.val \leftarrow nb.vallex \}$




Schéma de traduction :

$E \rightarrow T$ $T.val$ devient $E'.h$ au sommet
 E' $E'.val$ devient $E.h$ au sommet
 $E' \rightarrow +$
 T { $op2 \leftarrow sommet()$; $depiler()$; $op1 \leftarrow sommet()$; $depiler()$; $empiler(op1 + op2)$ } ₍₀₎
 E_1' $E_1'.val$ devient $E'.h$ au sommet
 $E' \rightarrow -$
 T { $op2 \leftarrow sommet()$; $depiler()$; $op1 \leftarrow sommet()$; $depiler()$; $empiler(op1 - op2)$ } ₍₁₎
 E_1' $E_1'.val$ devient $E'.h$ au sommet
 $E' \rightarrow \varepsilon$ $E'.val$ devient $E'.val$ au sommet
 $T \rightarrow ($
 E $E.val$ devient $T.val$ au sommet
 $)$
 $T \rightarrow nb$ $T.val$ apparait au sommet avec la valeur de $nb.vallex$

<u>Pile d'analyse</u>	<u>Pile d'attributs</u>	<u>Entrée</u>	<u>Productions</u>
\$E		5 – 3\$	E -> TE'
\$E'T		5 – 3\$	T -> nb
\$E'nb		5 – 3\$	
\$E'	5	– 3\$	E' -> -TE'
\$E' {1}T -	5	– 3\$	
\$E' {1}T	5	3\$	T -> nb
\$E' {1}nb	5	3\$	
\$E' {1}	5 3	\$	
\$E'	2	\$	E' -> ε
\$	2	\$	
/	2	/	

5.3.2 Analyse ascendante

Problème :

- l'arbre est construit en remontant des feuilles vers la racine.
- Les attributs hérités sont évalués en « descendant ».

Difficile d'évaluer des attributs dépendant d'autres attributs associés à des nœuds non encore produits par l'analyse syntaxique.

Observation : seules les actions sont importantes in fine.

On peut donc se contenter de calculer les attributs synthétisés (les actions peuvent être assimilées à des attributs synth.) et se ramener à la situation des définitions S-attribuées.

Pourquoi ça peut marcher (fréquemment) ?

Lorsque la valeur d'un attribut hérité est nécessaire au calcul d'un attribut, cet attribut dépend directement ou indirectement d'attributs liés à des symboles tous situés dans la pile. On peut remonter aussi loin que nécessaire dans la pile pour rechercher les val. synth. dont on a besoin. (ça ne marchera pas, en cas d'attribut hérité « spontané »).

13/11/2013




Schéma 1 (Voir titre).

Idée générale :

- Ne calculer que les attributs synthétisés
- Si la valeur d'un attribut hérité est nécessaire, remonter dans la pile pour y trouver les valeurs nécessaires


Certains schémas de traduction peuvent être directement construits sur cette base :

D → TL	L.type ← T.type
T → entier	T.type ← entier
T → réel	T.type ← réel
L → L ₁ , id	L ₁ .type ← L.type
	ajouter_type(id.entrée, L.type)
L → id	ajouter_type(id.entrée, L.type)

```

D → TL {dépiler()}
T → entier {empiler(INT)}
T → réel {empiler(REAL)}
L → L1, id {v ← sommet() ; dépiler() ; ajouter_type(v, sommet());}
L → id {v ← sommet() ; dépiler() ; ajouter_type (v, sommet());}
  
```

Pile d'analyse	Pile d'attributs	Entrée	Production	Actions
		réel p, q, r		
réel		p, q, r	T -> réel	
T	REAL	p, q, r		
T id	REAL p	, q, r	L -> id	
T L	REAL	, q, r		ajouter_type(p, REAL)
T L ,	REAL	q, r		
T L , id	REAL q	, r	L -> L, id	
T L	REAL	, r		ajouter_type(q, REAL)
T L ,	REAL	r		
T L , id	REAL r	/	L -> L, id	
T L	REAL			ajouter_type(r, REAL)
D	/			



D'autres définitions ne permettent pas de déterminer facilement les positions dans la pile de certains attributs indispensables au calcul. -> Mise en place de marqueurs.



Ex :

S -> a A C C.h <- A.s

S -> b A B C C.h < A.s

C -> c C.s <- g(C.h)


Schéma 3



Quand intervient une réduction par C -> c, l'attribut A.s nécessaire au calcul de C.h et donc de C.s se trouve, au choix, au sommet de la pile d'attributs ou juste en dessous, selon la production suivant laquelle on réduira ultérieurement. (sol : marqueurs !)

$s \rightarrow a A C$ $C.h \leftarrow A.s$
 $S \rightarrow b A B M C$ $M.h \leftarrow A.s$
 $C.h \leftarrow M.s$
 $C \rightarrow c$ $C.s \leftarrow g(C.h)$
 $M \rightarrow \epsilon$ $M.s \leftarrow M.h$

Schéma 4



Rq : Les marqueurs peuvent aussi être utilisés lorsque les règles sémantiques ne sont pas de sémantiques ne sont pas de simples copies.

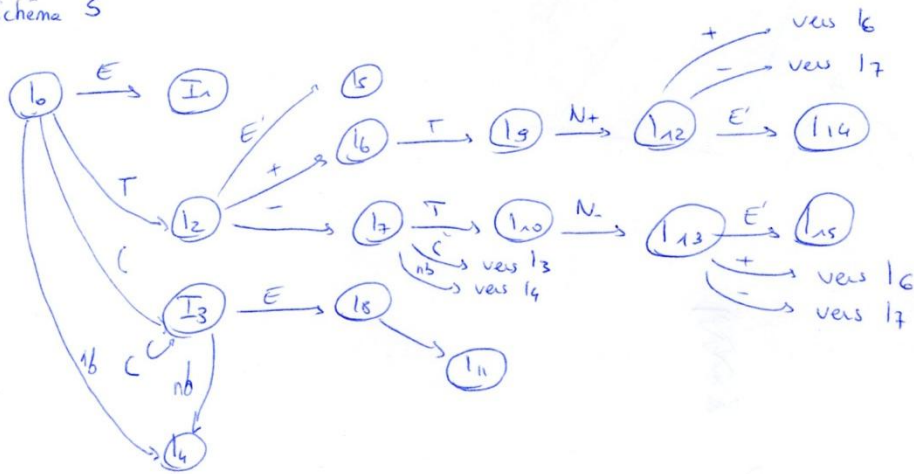
Ex :
 $S \rightarrow a A C$ $C.h \leftarrow f(A.s)$
 Devient
 $S \rightarrow a A N C$ $N.h \leftarrow f(A.s)$
 $C.h \leftarrow N.s$
 $N \rightarrow \epsilon$ $N.s \leftarrow N.h$

$E \rightarrow T E'$ $E' \rightarrow + T E_1'$ $E' \rightarrow - T E_1'$ $E' \rightarrow \epsilon$ $T \rightarrow (E)$ $T \rightarrow nb$	$\{E'.h \leftarrow T.val, E.val \leftarrow E'.val\}$ $\{E_1'.h \leftarrow E'.h + T.val, E'.val \leftarrow E_1'.val\}$ $\{E_1'.h \leftarrow E'.h - T.val, E'.val \leftarrow E_1'.val\}$ $\{E'.val \leftarrow E'.h\}$ $\{T.val \leftarrow E.val\}$ $\{T.val \leftarrow nb.vallex\}$
--	--

$E \rightarrow T E' \{ \}$
 $E' \rightarrow + T N_+ E' \{ \}$
 $E' \rightarrow - T N_- E' \{ \}$
 $E' \rightarrow \epsilon$
 $T \rightarrow (E) \{ \}$
 $T \rightarrow nb \{ \}$

$N_+ \rightarrow \epsilon \{ op2 \leftarrow sommet() ; \text{dépiler}() ; op1 \leftarrow sommet() ; \text{dépiler}() ; \text{empiler}(op1 + op2) \}$
 $N_- \rightarrow \epsilon \{ op2 \leftarrow sommet() ; \text{dépiler}() ; op1 \leftarrow sommet() ; \text{dépiler}() ; \text{empiler}(op1 - op2) \}$

Schéma S



<u>I0</u> S → .E E → .TE' T → .(E) T → .nb	<u>I1</u> S → E .	<u>I2</u> E → T .E' E' → .+TN ₊ E' E' → .-TN.E' E' → .	<u>I3</u> T → (.E) E → .TE' T → .(E) T → .nb	<u>I4</u> T → nb .	<u>I5</u> E → TE' .
<u>I6</u> E' → .+TN ₊ E' T → .(E) T → .nb	<u>I7</u> E' → .-TN.E' T → .(E) T → .nb	<u>I8</u> T → (E) .	<u>I9</u> E' → +T.N ₊ E' N ₊ → .	<u>I10</u> E' → -T.N.E' N ₋ → .	<u>I11</u> T → (E) .
<u>I12</u> E' → +TN ₊ .E' E' → .+TN ₊ E' E' → .-TN.E' E' → .	<u>I13</u> E' → -T N ₋ .E' E' → .+TN ₊ E' E' → .-TN.E' E' → .	<u>I14</u> E' → +TN ₊ E' .	<u>I15</u> E' → -TN.E' .		

<u>Pile d'analyse</u>	<u>Pile d'attributs</u>	<u>Entrée</u>	<u>Production</u>
0		5 - 3 + 2	
0 nb 4	5	- 3 + 2	T → nb
0 T 2	5	-3 + 2	
0 T 2 - 7	5	3 + 2	
0 T 2 - 7 nb 4	5 3	+ 2	T → nb
0 T 2 - 7 T 10	5 3	+ 2	N ₋ → ε
0 T 2 - 7 T 10 N ₋ 13	2	+ 2	
0 T 2 - 7 T 10 N ₋ 13 + 6	2	2	
0 T 2 - 7 T 10 N ₋ 13 + 6 nb 4	2 2	/	T → nb
0 T 2 - 7 T 10 N ₋ 13 + 6 T 9	2 2	/	N ₊ → ε
0 T 2 - 7 T 10 N ₋ 13 + 6 T 9 N ₊ 12	4	/	E' → ε
0 T 2 - 7 T 10 N ₋ 13 + 6 T 9 N ₊ 12 E' 14	4	/	E' → +T N ₊ E'
0 T 2 - 7 T 10 N ₋ 13 E' 15	4		E' → -T N ₋ E'
0 T 2 E' 5	4		E → TE'
0 E 1	4		accepter

